

Trabajo Grupal — Replicar el Pipeline Analítico

Módulo II: Preparación, Visualización y Preprocesamiento de Datos

Especialización en Business Intelligence & Business Analytics

Docente: Mag. Solange Basualdo

Este documento guía a cada grupo para replicar el mismo pipeline del caso Calidad Hospitalaria (Partes 0–10), pero con datos propios. La condición obligatoria: los 4 datasets deben estar alineados a una única pregunta analítica central que el grupo define y defiende desde el inicio.

1. Objetivo del trabajo

- Replicar en Python el pipeline completo: ingesta → calidad → missing → outliers → transformaciones → feature engineering → EDA → modelado → interpretación.
- Usar exactamente 4 datasets de fuentes reales (abiertos o autorizados).
- Demostrar que los 4 datasets responden conjuntamente a una pregunta analítica central.
- Entregar notebook reproducible, carpeta DAA_SI/ y presentación STAR.

2. Regla de oro: pregunta primero, datos después

No se acepta un trabajo donde los 4 datasets existan “porque estaban disponibles” sin relación clara con la pregunta. El flujo correcto es:

- Paso 1 — El grupo formula la pregunta analítica central (1 párrafo + variables de interés).
- Paso 2 — Identifica qué unidad de análisis necesita (ej. cliente, tienda, municipio, paciente).
- Paso 3 — Selecciona 4 datasets que aporten dimensiones distintas pero unibles para responder esa pregunta.
- Paso 4 — Define la clave de unión (join key) entre datasets antes de descargar o limpiar.
- Paso 5 — Ejecuta el pipeline siguiendo Caso_1_Solucion_v1.ipynb como plantilla estructural.

3. Cómo redactar la pregunta analítica central

La pregunta debe cumplir cinco criterios (checklist de aprobación del docente):

Criterio	Descripción	Ejemplo (caso hospitalario)
Específica	No es tema general; pide una relación o predicción concreta	¿Qué combinación de factores operacionales y socioeconómicos predice readmisión elevada y baja satisfacción?
Responsible con datos	Se puede operacionalizar con	ERR, HCAHPS, rating CMS,

	variables medibles	pobreza del condado
Multidataset	Requiere al menos 2 niveles o fuentes distintas	Hospital (D1–D3) + Condado (D4)
Relevante para negocio	Un stakeholder tomaría decisiones con la respuesta	Director de Salud prioriza hospitales de riesgo
Temporalmente acotada	Indica período o cohorte si aplica	Datos CMS FY2026 + County Rankings 2025

Plantilla obligatoria (copiar al inicio del notebook del grupo):

“¿Qué combinación de [factores operacionales / internos de la unidad A] y [factores contextuales / externos de la unidad B] predice mejor [resultado negativo de interés], y qué segmentos emergen de ese patrón?”

4. Los 4 datasets: requisitos y roles

Cada grupo debe tener exactamente 4 datasets. Cada uno cumple un rol distinto en la respuesta a la pregunta. Todos deben poder unirse al dataset maestro final.

Dataset	Rol típico	Nivel de granularidad	Ejemplo caso referencia
D1 — Entidad principal	Quién es el objeto de estudio (identidad, tipo, categoría)	Unidad principal (1 fila por entidad)	Hospital General Information (CMS)
D2 — Comportamiento / experiencia	Métrica de desempeño o percepción (a menudo formato largo)	Misma unidad que D1 o agregable	HCAHPS satisfacción del paciente
D3 — Resultado crítico	Variable dependiente o KPI de riesgo (outcome)	Misma unidad que D1	HRRP exceso de readmisiones
D4 — Contexto externo	Factores del entorno que modulan el desempeño	Geografía, mercado o segmento superior/inferior	County Health Rankings

4.1 Matriz de coherencia (entregar en Semana 1)

Antes de avanzar con el código, cada grupo completa esta matriz y la envía al docente:

Celda	Qué documentar	Ejemplo grupo retail	Ejemplo grupo educación
Pregunta central	Texto completo de la pregunta	¿Qué mix de operación de tienda y perfil socioeconómico del distrito predice baja satisfacción NPS y alta tasa de devoluciones?	¿Qué factores institucionales y del municipio predicen alta deserción y bajo puntaje de aprendizaje?
D1	Fuente, URL, filas, clave primaria	Catálogo tiendas (store_id)	Directorio colegios (school_id)
D2	Qué dimensión aporta	Encuestas NPS por	Satisfacción familia /

	a la pregunta	tienda	clima escolar
D3	Outcome principal (riesgo)	Tasa de devoluciones	Tasa de deserción o reprobación
D4	Contexto externo	Censo / ingreso por distrito	Indicadores municipales (pobreza, empleo)
Join key	Cómo se unen D1 con D4	store_id → distrito_id → censo	school_id → municipio_id → indicadores
Stakeholder	Quién usa el resultado	Gerente regional retail	Ministerio de Educación regional

4.2 Criterios mínimos de calidad de los datos elegidos

- Fuente identificable y citada (URL, organismo, fecha de extracción).
- Licencia o uso académico permitido.
- Mínimo 500 filas en D1 (salvo justificación de nicho).
- Al menos 15% de valores faltantes en alguna variable clave (para aplicar Parte 4 con sentido).
- Al menos una variable numérica y una categórica por dataset relevante.
- D2 o D3 puede venir en formato largo (tall); el grupo debe pivotar a ancho como en el caso.
- D4 debe ser de nivel contextual (no duplicar D1).

5. Estructura de carpetas (igual al caso)

Cada grupo replica esta estructura. Los datos crudos no se modifican.

```

proyecto_grupo_X/
├── DAA_SI/
│   ├── datos_raw/           ← 4 CSV originales, intocables
│   ├── datos_limpios/       ← dataset_maestro.csv y tablas finales
│   └── evidencias/          ← gráficos E02–E17 (misma numeración)
├── Notebook_Grupo_X.ipynb  ← pipeline completo Partes 0–10
├── Presentacion_STAR.pptx
└── README.md                ← pregunta, fuentes, integrantes, instrucciones de ejecución

```

6. Pipeline a replicar — Parte por parte

Usar Caso_1_Solucion_v1.ipynb como plantilla estructural. Los nombres de variables cambian; la lógica no.

Parte 0 — Configuración

Qué hacer: Librerías, paleta, carpetas RAW/CLEAN/EVID. Celdas de setup idénticas al caso.

Entregable: Entrega: confirmación de rutas en consola.

Parte 1 — Ingesta

Qué hacer: Cargar 4 CSV con encoding utf-8-sig. Documentar dimensiones y trampas de ingesta (BOM, "N/A", tipos).

Entregable: Entrega: tabla con filas $\times$ columnas de D1–D4.

Parte 2 — Perfilado

Qué hacer: Función `perfil_rapido()` por dataset: tipos, nulos, duplicados, rangos.

Entregable: Entrega: diagnóstico escrito de 3 problemas principales por dataset.

Parte 3 — Calidad de datos

Qué hacer: 5 dimensiones: Completitud, Unicidad, Consistencia, Validez, Actualidad. Pivot si D2/D3 es largo. Crear clave de unión con D4.

Entregable: Entrega: E02 + tabla de issues y acciones.

Parte 4 — Valores faltantes

Qué hacer: 4 tests: Little MCAR, correlación indicadores, KS, footnotes/códigos de ausencia. Imputación: Media/Mediana/Moda/KNN/MICE. Métricas E10.

Entregable: Entrega: plan de imputación justificado + final_datasets.

Parte 5 — Outliers

Qué hacer: IQR, Z-Score, Isolation Forest sobre la variable outcome principal. Winsorización.

Entregable: Entrega: E11 + justificación de no eliminar registros.

Parte 6 — Transformaciones

Qué hacer: Min-Max o StandardScaler en numéricas; encoding categóricas (One-Hot / flags).

Entregable: Entrega: E12 distribuciones antes/después.

Parte 7 — Feature Engineering

Qué hacer: Construir `dataset_maestro` uniendo los 4 datasets. Crear 2 índices compuestos con fórmula explícita y pesos justificados (equivalente HQI + SVI).

Entregable: Entrega: dataset_maestro.csv + documentación de fórmulas.

Parte 8 — EDA avanzado

Qué hacer: 3 hipótesis alineadas a la pregunta central. Scatter, boxplot, heatmap.

Entregable: Entrega: E13, E14, E15 con interpretación escrita.

Parte 9 — Negocio

Qué hacer: Informe ejecutivo, ranking top-N entidades de riesgo, dashboard E17, recomendaciones por stakeholder.

Entregable: Entrega: CSV ranking + E17 + texto STAR Result.

7. Índices compuestos propios (obligatorio)

Cada grupo debe crear dos índices, no copiar HQI/SVI literalmente. Deben estar ligados a la pregunta analítica:

Índice	Qué mide	Requisitos	Ejemplo retail
Índice A (desempeño)	Calidad / resultado interno de la entidad	≥2 variables de D1–D3; pesos suman 1; fórmula en markdown	$TDI = 0.5 \times NPS_{norm} + 0.3 \times (1 - \text{devoluciones}) + 0.2 \times \text{cumplimiento}$
Índice B (contexto)	Vulnerabilidad o potencial del entorno (D4)	≥2 variables D4; interpretación para no técnicos	$IVD = 0.4 \times \text{pobreza} + 0.4 \times \text{baja_movilidad} + 0.2 \times (1 - \text{competencia})$

- El índice A debe incorporar las dos dimensiones de la pregunta (outcome + percepción/experiencia).
- El índice B contextualiza sin culpar a la entidad por factores externos.

8. Variable objetivo y segmentación

Derivar de la pregunta, no copiar low_quality del caso sin adaptar:

Concepto	Cómo definirlo en el grupo	Ejemplo
Outcome principal	La variable “mala” que la pregunta busca predecir	ERR > 1.0, devoluciones > P75, deserción > media
Outcome secundario	Segunda dimensión de la pregunta	Satisfacción en Q25 inferior, NPS < 30
Doble riesgo	Intersección de ambos outcomes	ERR alto AND satisfacción baja
Target modelo	Binario para clasificación	desempeño_bajo = 1 si Índice A ≤ Q25

9. Entregables finales

#	Entregable	Formato
1	Matriz de coherencia (Sección 4.1)	Word o celda markdown notebook
2	Notebook Partes 0–4	.ipynb ejecutable
3	Notebook Partes 5–7 + dataset_maestro	.ipynb + CSV

4	Notebook Partes 8–10 + evidencias	.ipynb + PNG + CSV ranking
5	Presentación STAR	.pptx 15–20 diapositivas
6	ZIP del proyecto	DAA_SI/ + notebook + README

10. Rúbrica de evaluación (20 puntos)

Criterio	Puntos	Excelente (90–100%)	Insuficiente (<50%)
Coherencia pregunta ↔ 4 datasets	5	Los 4 datasets son indispensables para responder; join keys claras	Datasets desconectados o D4 redundante con D1
Pipeline técnico (Partes 0–7)	5	Todas las partes ejecutan sin error; imputación justificada con tests	Salto de etapas; imputación sin diagnóstico MCAR/MAR/MNAR
Índices, EDA y modelado (Partes 8–9)	4	Índices propios, hipótesis validadas, clusters interpretados	Índices copiados del caso; clusters sin etiqueta de negocio
Interpretación y stakeholders (Parte 10)	3	Recomendaciones accionables por rol; ranking útil	Solo gráficos sin narrativa de negocio
Reproducibilidad y documentación	2	README, fuentes citadas, rutas relativas, ZIP ordenado	Notebook no corre en máquina del docente
Presentación STAR	1	S-T-A-R claros; pregunta central en slide Task	Solo lectura de código sin historia de negocio

11. Errores frecuentes a evitar

Elegir 4 datasets del mismo nivel

Si los 4 son “por tienda”, no hay contexto D4. Falta la dimensión externa.

Pregunta genérica

“Analizar la calidad de los datos” no es pregunta analítica; es objetivo de curso.

Sin clave de unión

D1 y D4 no se pueden cruzar → no hay dataset maestro válido.

Copiar código sin adaptar nombres

Facility ID, county_join, HQI no aplican a retail/educación sin redefinir.

Imputar todo con la media

Deben comparar al menos 3 métodos y elegir con métricas E10.

Eliminar outliers

En el caso se winsoriza; eliminar registros requiere justificación de negocio.

Modelo circular

Predecir un índice usando sus propios componentes infla el AUC sin valor real.

Gráficos sin código E##

Mantener numeración E02–E17 para facilitar revisión y comparación entre grupos.

12. Ejemplos de preguntas válidas por dominio

Dominio	Pregunta analítica central	D1	D2	D3	D4
Retail	¿Qué mix operacional de tienda y perfil del distrito predice baja satisfacción y alta devolución?	Tiendas	NPS/encuestas	Devoluciones	Censo distrito
Educación	¿Qué factores escolares y municipales predicen deserción y bajo aprendizaje?	Colegios	Clima escolar	Deserción/IDE	Indicadores municipio
Banca	¿Qué perfil de sucursal y zona económica predice alta mora y bajo NPS?	Sucursales	Satisfacción cliente	Mora / NPL	PIB / desempleo local
Logística	¿Qué operación de centro de distribución y contexto regional predicen retrasos y	CDs / hubs	Satisfacción transportista	OTIF / retrasos	Infraestructura regional

	bajas calificaciones?				
Hospitalario (referencia)	¿Qué factores hospital y condado predicen readmisión elevada y baja satisfacción?	Hospitales CMS	HCAHPS	HRRP readmisiones	County Health Rankings

13. Checklist final antes de entregar

- ☐ La pregunta analítica central está en la primera celda markdown del notebook.
- ☐ La matriz de coherencia (Sección 4.1) está completa y coincide con el notebook.
- ☐ Los 4 CSV están en datos_raw/ sin modificar.
- ☐ dataset_maestro.csv tiene una fila por entidad principal (D1).
- ☐ Existen al menos 10 evidencias PNG (E02–E17) en evidencias/.
- ☐ Los dos índices compuestos tienen fórmula escrita y pesos justificados.
- ☐ Hay un CSV de ranking de riesgo (equivalente hospitales_mayor_riesgo.csv).
- ☐ La presentación STAR tiene slide de stakeholders y slide de respuesta a la pregunta.
- ☐ README indica cómo ejecutar el notebook de principio a fin.
- ☐ El ZIP se genera al final del notebook (celda de exportación).

14. Referencias del curso

- Notebook plantilla: caso analitico/Caso_1_Solucion_v1.ipynb
- Presentación STAR referencia: Presentacion_STAR_Calidad_Hospitalaria.pptx